# ВМСиС

Лекция 2

Представление данных в памяти ЭВМ

# Представление данных в ЭВМ

- Все данные хранятся в двоичном виде - 0101011010110011
- Значение данных определяется программой, и изображения и видео и текст в памяти ничем не отличаются
- **Бит** - минимальная единица хранения информации
- **Байт** - минимальная адресуемая единица хранения информации
  *1 байт = 8 бит, и может принимать одно из $2^8$ значений (обычно)*
- **Слово** - количество байт, которое процессор может передать по шине данных за один такт. Для 16 битных процессоров слово = 2 байта, для 64 битных - 8 байт

# Представление чисел в памяти

- Для хранения чисел используются числа различной разрядности, кратные степени двойки - 1, 2, 4, 8 байт.
- Беззнаковые числа могут принимать значения от 0 до $2^n$-1, n - разрядность числа
- Знаковые числа хранятся в дополнительном коде и могут принимать значения от $-2^{n-1}$ до $2^{n-1}$-1
- Вещественные числа хранятся в формате с плавающей точкой

# Системы счисления

- Непозиционные - значение символа не зависит от позиции
  - Римская
  - и многие другие древние системы

- Позиционные - значение символа зависит от его позици в числе
  - Десятичная
  - Двоичная
  - Шестнадцатеричная

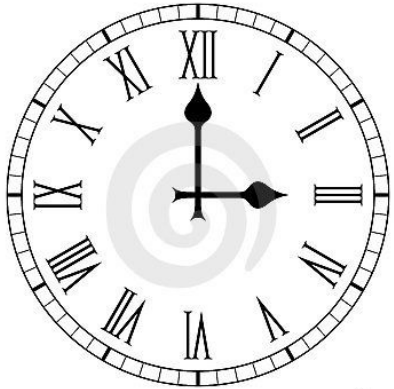

# Позиционная система счисления

- Основание - количество символов в одном разряде
  - В десятичной системе - основание 10
  - В двоичной - 2
  - В системе счисления часов - 24, минут и секунд - 60
- Цифры - все возможные значения каждого разряда числа
  - Десятичная система - 0, 1, 2, 3, 4, 5, 6, 7, 8, 9
  - Двоичная система - 0, 1
  - Шестнадцатеричная система - 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F

В вычислительной технике чаще всего применяют двоичную и шестнадцатеричную системы счисления

# Двоичная система счисления

- Алфавит состоит из двух цифр - 0 и 1
- Легко хранить и передавать в вычислительных системах:
  - Нулевого и положительного электрического потенциала
  - Направление магнитного потока
  - И т.д.
- Позволяет закодировать любые данные

| | |
|---|---|
| 0 | 0 |
| 1 | 1 |
| 2 | 10 |
| 3 | 11 |
| 4 | 100 |
| 5 | 101 |

# Шестнадцатеричная система счисления

- Алфавит состоит из десятичных цифр и первых 6 букв латинского алфавита: **0123456789ABCDEF**
- Используется для короткой записи двоичных данных
- Все значения 1 Б данных могут быть представлены двумя разрядами
- При записи используется префикс **0x**, либо суффикс **h**

| | |
|---|---|
| 0 | 0x0 |
| 10 | 0xA |
| 16 | 0x10 |
| 255 | 0xFF |
| 1024 | 0x400 |

# Перевод из одной системы счисления в другую

Для перевода числа N из системы счисления с основанием X в систему счисления с основанием Y необходимо делить это число на Y до получения остатка меньшего Y. Полученное частное необходимо снова делить на Y, до получения остатка меньшего Y и так до тех пор пока частное будет меньше Y. Затем нужно записать остатки в порядке их получения. Это и будет искомое число в системе счисления Y

# Перевод из 10 в 16

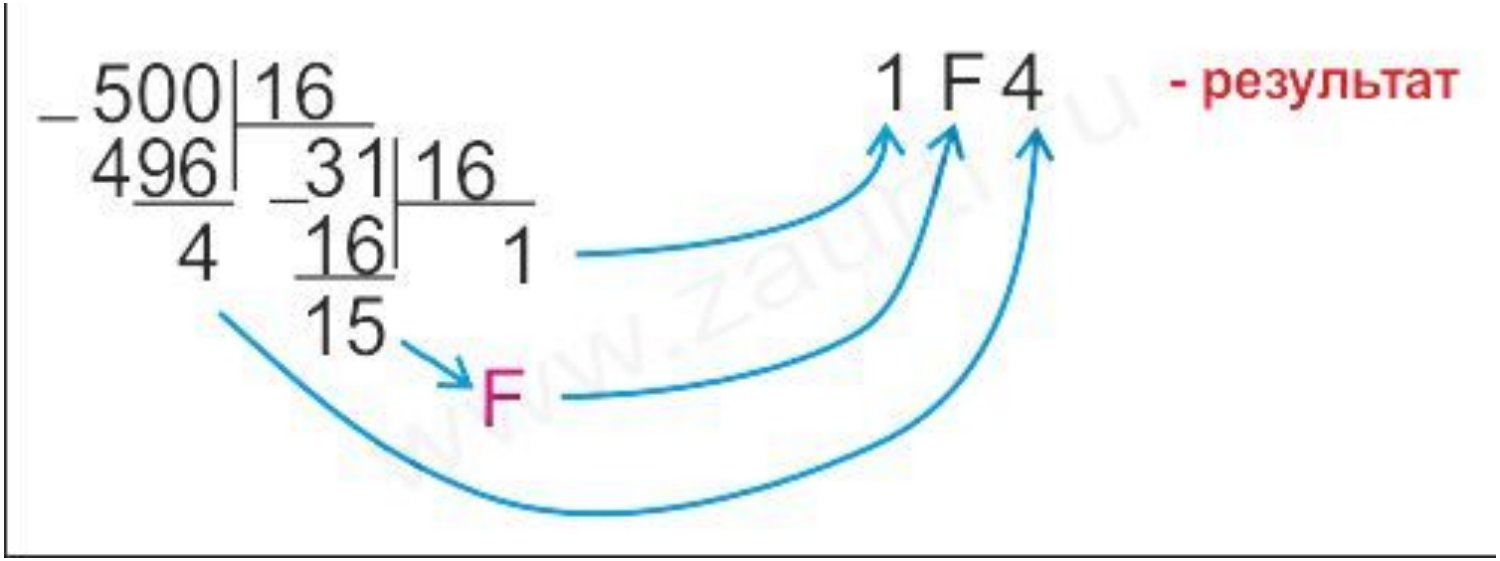

# Перевод в десятичную систему

Для перевода в десятичную систему необходимо разложить число в сумму степеней номеров разрядов умноженных на цифру разряда:

$0x1F4 = 1 * 16^2 + 15 * 16^1 + 4 * 16^0 = 256 + 240 + 4 = 500$

$0b11101011 = 1 * 2^7 + 1 * 2^6 + 1 * 2^5 + 0 * 2^4 + 1 * 2^3 + 0 * 2^2 + 1 * 2^1 + 1 * 2^0 =$

$= 128 + 64 + 32 + 0 + 8 + 0 + 2 + 1 = 235$

# Перевод из 16 в 2

| Десятичные числа | Шестнадцатеричные числа | Двоичные числа |
|---|---|---|
| 0 | 0 | 0000 |
| 1 | 1 | 0001 |
| 2 | 2 | 0010 |
| 3 | 3 | 0011 |
| 4 | 4 | 0100 |
| 5 | 5 | 0101 |
| 6 | 6 | 0110 |
| 7 | 7 | 0111 |
| 8 | 8 | 1000 |
| 9 | 9 | 1001 |
| 10 | A | 1010 |
| 11 | B | 1011 |
| 12 | C | 1100 |
| 13 | D | 1101 |
| 14 | E | 1110 |
| 15 | F | 1111 |

0xFF = 1111 1111 = 15 * 16 + 15 = 255

0x80 = 1000 0000 = 8 * 16 + 0 = 128

0x10 = 0001 0000 = 1 * 16 + 0 = 16

0xAB = 1010 1011 = 10 * 16 + 11 = 171

0x63 = 0110 0011 = 6 * 16 + 3 = 99

0x93 = 1001 0011 = 9 * 16 + 3 = 147

0xD5 = 1101 0101 = 13 * 16 + 5 = 213

# Порядок байтов в многобайтовых числах

- Память ЭВМ делится на байты (как атомы, можно еще меньше, но нельзя)
- С помощью одного байта можно сохранить число от 0 до 255. Больше никак.
- Чтобы сохранить число значением больше 255 его нужно разбить на несколько байтов

4660 = 0x1234 = [12] [34]

# Тупоконечники и остроконечники

Нужно сохранить число 0x1234

Можно записать как [12] [34] - **Big endian** - Выглядит хорошо

Можно записать как [34] [12] - **Little endian** - Выглядит плохо

ushort a = 0x1234;

byte b = (byte) a; // ?????

- Big endian b = 0x34;
- Little endian b = 0x12;

ushort a = 0x0064;

byte b = (byte) a; // ?????

- Big endian b = 0x00;
- Little endian b = 0x64;

# Знаковые и беззнаковые целые числа

- Беззнаковые числа **не могут** принимать отрицательные значения
- Знаковые - **могут**

- Как хранить отрицательные числа?

# Система со знаком

- Старший разряд используется для указания знака числа
- 0 - положительное число
- 1 - отрицательное число

Пример:

```
00000001 =  1       00000000 = +0
10000001 = -1       10000000 = -0
10001000 = -8
```

- Понятно человеку
- **Не понятно ЭВМ**

# Двоичный дополненный код

- Старший разряд используется для указания знака числа
- 0 - положительное число
- 1 - отрицательное число
- Отрицательное число инвертируется и к нему прибавляется 1

Пример:

```
00000001 =  1       1000000 = -128
11111110 = -1       0111111 = 127
11111011 = -5
```

- Не понятно человеку
- **Понятно ЭВМ**

# Вычитание двоичных чисел

- Вычитания нет, есть только сложение
- Вычитаемое заменяется на число в двоично-дополненном коде
- Числа складываются

Пример:

| | | |
|---|---|---|
| 10 – 7 = 3 | _ 00001010<br>  00000111<br>= 00000011 | 00001010<br>+ 11111001<br>=100000011 |

# Вещественные числа

- Числа с плавающей запятой
  - одинарной точности - single precision, float
  - двойной точности - double precision
- Числа с фиксированной запятой

# IEEE 754

- Стандарт описывает принципы представления чисел с плавающей запятой
- Поддерживается подавляющим числом ЭВМ и языков программирования

Вещественное число представляется основанием (b) и тремя целыми числами:

- S - Знак
- Q - Порядок (экспонента)
- C - Мантисса

$$(-1)^S \times C \times b^Q$$

$$S = 1$$
$$C = 12345$$
$$Q = -3$$
$$(-1)^1 \times 12345 \times 10^{-3} = 12.345$$

# IEEE 754 - представление в ЭВМ

- Мантисса всегда хранится в нормализованном формате:
  - 1.xxxxxxx
- Ведущая единица отбрасывается для экономии памяти, хранится только часть после запятой
- Экспонента записывается со смещением зависящим от точности числа
  - Одинарная точность: $2^7-1 = 127$
  - Двойная точность: $2^{10}-1 = 1023$

# Числа одинарной точности

- В языках программирования часто обозначаются как float
- Описывается стандартом IEEE 754 и имеет размер 4 байта
- Основание b=2
- Смещение экспоненты $2^7-1 = 127$
- Количество разрядов мантиссы - 24

# Пример


$$S = 0$$

$$C = 1.01_2 = 1.25_{10}$$

$$Q = 1111100_2 - 1111111_2 = -3_{10}$$

$$(-1)^0 \times 1.25 \times 2^{-3} = 0.15625$$

# Числа двойной точности

- В языках программирования часто обозначаются как float
- Описывается стандартом IEEE 754 и имеет размер 8 байта
- Основание b=2
- Смещение экспоненты $2^{10}-1 = 1023$
- Количество разрядов мантиссы - 52

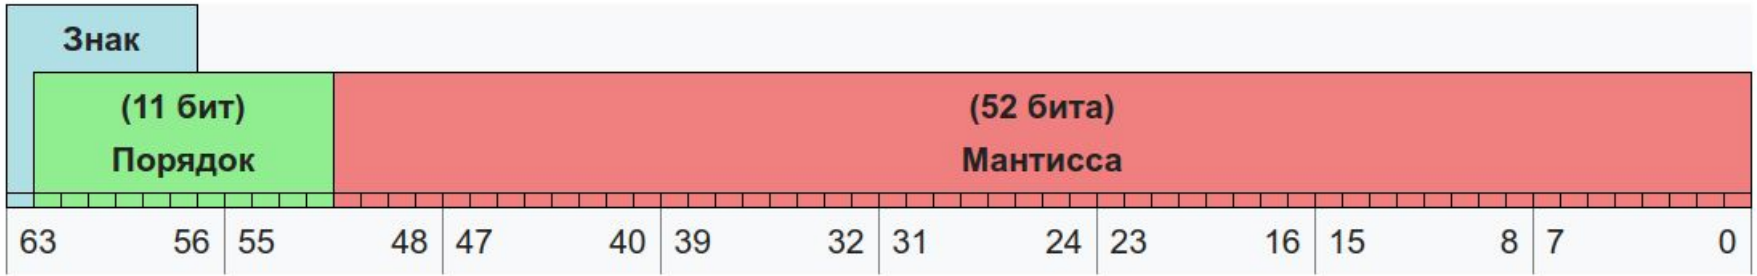

# Что будет выведено на экран?

```
1  #include <iostream>
2  #include <string>
3  #include <stdio.h>
4
5  int main()
6  {
7    double da = 9999999999999999.0;
8    double db = 9999999999999997.0;
9    float fa = 9999999999999999.0f;
10   float fb = 9999999999999997.0f;
11   printf("da - db = %f\n", da - db);
12   printf("fa - fb = %f\n", fa - fb);
13 }
```

Double: 2^52 = 4 503 599 627 370 496

A = 9 999 999 999 999 999.0 -> 1 000 000 000 000 000.0
B = 9 999 999 999 999 998.0 -> 9 999 999 999 999 996.0
A - B = 4

Float: 2 ^ 24 = 16777216

A = 9 999 999 999 999 999.0 -> 1 000 000 000 000 000.0
B = 9 999 999 999 999 999.0 -> 1 000 000 000 000 000.0
A - B = 0

# Представление текста в памяти ЭВМ

- Как и все данные, текст в ЭВМ хранится в виде 0 и 1
- Мы договорились что 01000001 - ‘A’, 01000010 - ‘B’ и т.д.
- Такая договоренность называется “КОДИРОВКА”

Широко используемые кодировки с поддержкой кириллицы:

- Code page 1251 - Кириллическая Windows
- Code page 866 - Кириллическая DOS
- KOI-8 - Кириллическая Unix
- UTF-8 - современные ОС и web

# ASCII

- Разработана в 1963 году
- Кодирует латинские символы и управляющие последовательности 7 битами, старший бит - бит четности
- $2^7$ = 128 позиций

**ASCII Code Chart**

| | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | A | B | C | D | E | F |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | NUL | SOH | STX | ETX | EOT | ENQ | ACK | BEL | BS | HT | LF | VT | FF | CR | SO | SI |
| 1 | DLE | DC1 | DC2 | DC3 | DC4 | NAK | SYN | ETB | CAN | EM | SUB | ESC | FS | GS | RS | US |
| 2 | | ! | " | # | $ | % | & | ' | ( | ) | * | + | , | - | . | / |
| 3 | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | : | ; | < | = | > | ? |
| 4 | @ | A | B | C | D | E | F | G | H | I | J | K | L | M | N | O |
| 5 | P | Q | R | S | T | U | V | W | X | Y | Z | [ | \ | ] | ^ | _ |
| 6 | ` | a | b | c | d | e | f | g | h | i | j | k | l | m | n | o |
| 7 | p | q | r | s | t | u | v | w | x | y | z | { | \| | } | ~ | DEL |

# Проблемы несовместимости кодировок

хъёђ яю№ђшђёп ш ёђрэютшђёп эхїшђрхьћь я№ш хую шэђх№я№шђрішш їх№хч эхтх№эґў ъюфш№ютъґ:

- №ш тћтюфх т ъюэёюыќ т Windows
- №ш эхтх№эю эрёђ№юхээюь с№рґчх№х
- №ш эхя№ртшыќэћs j№шєђрs
- х№тюьґ ъђю §ђю ях№хтхфхђ чрїђґ ях№тґў ырсґ схч тћяюыэхэшп тю ьэюушs ф№ґушs ёыґїрпs

# Unicode спешит на помощь

- Единая кодировка для всех
- Кодирует “все” возможные символы
  - Буквы
  - Иероглифы
  - Математические символы
  - Музыкальные ноты
  - И многое другое
- 16 бит - хватит всем!

# Существующие форматы представления Unicode

- Несколько устаревших и не рекомендованных к использованию
- UTF-8
- UTF-16BE
- UTF-16LE
- UTF-32BE
- UTF-32LE

# UTF-8

- Кодировка использует переменную длину символа
- Первые 127 символов полностью повторяют ASCII и кодируются 1 байтом
- Национальные и специальные символы могут иметь длину от 2 до 4 байт
- Кириллические символы кодируются 2 байтами

# BOM - Маркер последовательности байтов

- UTF-8 EF BB BF
- UTF-16 (BE) FE FF
- UTF-16 (LE) FF FE
- UTF-32 (BE) 00 00 FE FF
- UTF-32 (LE) FF FE 00 00

# Состояние на сегодняшний момент

- 90% WEB-страниц использует кодировку UTF-8
- Все современные ОС поддерживают Unicode в том или ином виде
- Visual Studio C++ с настройками по умолчанию выводит кракозябры в консоли